

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/383594846>

МЕТОД АВТОМАТИЧЕСКОЙ УВЯЗКИ РЕЗУЛЬТАТОВ ГЕОФИЗИЧЕСКИХ ИССЛЕДОВАНИЙ СКВАЖИН С ФОТОГРАФИЯМИ КЕРНА (A METHOD FOR AUTOMATED DEPTH-SHIFTING OF GWL CU....)

Article · August 2024

DOI: 10.34926/geo.2024.94.33.006

CITATIONS

0

2 authors:



Vladimir Abashkin

SMR

23 PUBLICATIONS 112 CITATIONS

[SEE PROFILE](#)

READS

48

12 PUBLICATIONS 11 CITATIONS

[SEE PROFILE](#)



Georgy Kossov

Moscow Institute of Physics and Technology

МЕТОД АВТОМАТИЧЕСКОЙ УВЯЗКИ РЕЗУЛЬТАТОВ ГЕОФИЗИЧЕСКИХ ИССЛЕДОВАНИЙ СКВАЖИН С ФОТОГРАФИЯМИ КЕРНА

В.В. Абашкин, Г.А. Коссов

ООО «Технологическая компания Шлюмберже». 125171, Россия, Москва, Ленинградское шоссе, 16А, строение 3. Email: gkossov@slb.com

Аннотация. Настоящая работа посвящена проблеме автоматической привязки каротажных кривых к фотографиям полноразмерного керна. В статье рассматривается синтетический набор данных плотностного каротажа, содержащий сдвинутые кривые с различными искажениями. Для решения данной задачи была разработана методика, использующая для привязки алгоритм поэтапных обратных свёрток. В процессе привязки используется литологическая колонка, полученная по фотографиям керна с применением метода автоматического литотипирования и содержащая геологическую информацию о разрезе. Анализ результатов обработки синтетического набора данных позволил сделать выводы о высокой точности привязки, которая составила величину шага дискретизации. Данный инструмент позволяет значительно сократить время интерпретации результатов геофизических исследований скважин по сравнению с традиционными подходами и может служить основой для дальнейших исследований в этой области.

Ключевые слова. Геофизические исследования скважин, увязка данных, автоматическое литотипирование, фотографии керна

AUTOMATED WORKFLOW FOR DEPTH-SHIFTING OF GEOPHYSICAL WELL LOGGING CURVES TO THE WHOLE CORE IMAGES

V.V. Abashkin, G.A. Kossov

LLC Schlumberger. 125171, Russia, Moscow, Leningradskoye shosse st., 16A, building 3. Email: gkossov@slb.com

Abstract. In this paper, we propose a novel approach to the problem of automatic depth-shifting of logging curves to the whole core images. We consider a synthetic dataset that contains whole core images and shifted density logging curves with various distortions. An automatic lithotyping method is used to extract a lithological column from the core images (geological information) during shifting process. By analyzing the results of processing a synthetic dataset, we determine the high accuracy of the processing. Our approach reduces the time needed to analysis the results of geophysical well logging compared to the traditional approaches.

Keywords. Geophysical well logging, depth-shifting, automated lithotyping, whole core images

Введение.

Основной целью проведения геологоразведочных работ (ГРР) является определение внутреннего строения земной коры и глубин залегания полезных ископаемых для их последующего извлечения. Комплекс методов геофизических исследований скважин (ГИС) используется для изучения геологического строения разреза и характеристик горных пород в околоскважинном пространстве. Каротаж скважин предоставляет важную петрофизическую и геомеханическую информацию, которая может быть существенной на различных этапах жизненного цикла скважины [18, 19]. Удорожание ГРР (в том числе и ГИС) ставит вопрос повышения эффективности методов анализа результатов геофизических исследований. Основная цель совершенствования существующих подходов интерпретации ГИС — это извлечение максимального объёма информации из имеющегося комплекса за короткое время.

Однако полученные каротажные кривые часто характеризуются рядом неопределенностей, что делает предварительную обработку необходимым этапом для их последующего анализа. Современные приборы ГИС имеют ряд ограничений: одним из которых является конечное вертикальное разрешение, которое ограничивает точность определения интервалов сбора данных. К тому же измерения в процессе различных спускоподъёмных операций могут быть несогласованными. Данные, полученные из различных источников, могут иметь разнородные форматы, точность и уровень детализации (включая конечное вертикальное разрешение), что приводит к определенным трудностям при уточнении глубин залегания пластов. Увязка каротажных кривых (как между собой, так и с лабораторными измерениями, фотографи-

ями керна, томографией и т.п.) является одним из ключевых этапов предварительной обработки данных [4]. Совместный анализ таких данных при дальнейшей петрофизической интерпретации представляет трудности без разработки определённых подходов для согласования кривых ГИС с фотографиями керна. Несогласованность данных может быть вызвана несколькими факторами: разное вертикальное разрешение приборов, измерения в процессе различных спускоподъёмных операциях, трение между прибором и стенкой скважины (если стенка скважины шероховатая, содержит глинистую корку или имеются вывалы породы), растяжение кабеля и т.д. [1]

Нефтяная и газовая промышленность до сих пор в значительной степени полагается на суждения специалистов-петрофизиков, которые вручную увязывают несоппадающие кривые, прежде чем приступать к непосредственной интерпретации [3, 4]. Тем не менее, этот традиционный процесс увязки, зависящий от человека, субъективен, отнимает много времени и требует наличия определенного опыта. К тому же такой подход неприменим к увязке данных каротажа, полученных во время бурения из-за временных ограничений (петрофизическая интерпретация должна быть оперативной). Поэтому всё больше становится актуальной задача разработки автоматических методик и алгоритмов, для увеличения эффективности работы специалистов.

Автоматизация обработки каротажных данных скважин может ускорить и повысить качество их дальнейшей петрофизической интерпретации. Благодаря наличию большого накопленного объёма данных, высокой вычислительной мощности современных ПК и разработке алгоритмов искусственного интеллекта (ИИ) нефтегазовая промышленность в

настоящее время использует цифровые технологии практически во всех направлениях, включая уточнение глубин залегания пластов по ГИС. В литературе различные парадигмы машинного обучения нашли применение в автоматизации предварительной обработки и интерпретации каротажа скважин [13, 16, 18, 19].

Например, в работах [18, 19] решается проблема увязки данных комплекса ГИС с использованием методов машинного обучения, но разными подходами. В работе [19] авторы с помощью обученной полносвязной нейронной сети предсказывают величину сдвига каротажной кривой. Напротив, в работе [18] предложена 1-Д сверточная нейронная сеть, которая решает задачу регрессии и была обучена на результатах гамма-, плотностного, акустического, нейтронного каротажа, данных сопротивления и фотоэлектрического фактора. Обе работы рассматривают идеализированный случай постоянного сдвига и неискажённых кривых ГИС. Данные алгоритмы показали высокую точность предсказания в интервале увязки ~ 3 м. Однако вышеупомянутые подходы имеют некоторые ограничения: невозможность прогнозировать переменный сдвиг кривой, необходимость предварительной «разметки» данных для обучения, множество настраиваемых параметров (гиперпараметров), долгое время обучения (в некоторых случаях до 4 часов [18]) и невозможность выполнять привязку к фотографиям керна. К тому же из-за сложности реализации используемых алгоритмов, таких как свёрточные нейронные сети, сообщество искусственного интеллекта в значительной степени зависит от сторонних библиотек с открытым исходным кодом, таких как TensorFlow и Pytorch.

Распространенными методами увязки также являются подходы, основанные на кросс-корреляции, включая как частично автоматические, так и полностью автоматические инструменты [12]. Эти алгоритмы быстры, хорошо изучены, надежны и дают легко интерпретируемые результаты. Но при этом они также применимы только для увязки кривых ГИС между собой и не позволяют напрямую увязывать фотографии керна с данными ГИС. Для привязки керновых данных используют стандартный подход, заключающийся в измерении естественного гамма-излучения образцов керна [10] и последующей их привязки к каротажу с использованием алгоритмов кросс-корреляции. Однако данный метод требует дополнительных затрат времени на лабораторные исследования и не решает вопрос учета литологии в процессе вычислений. К тому же, в случае неконтрастной кривой естественной гамма активности (например, при обработке чистых неглинистых карбонатных разрезов) увязка вышеописанными методами может представлять трудности.

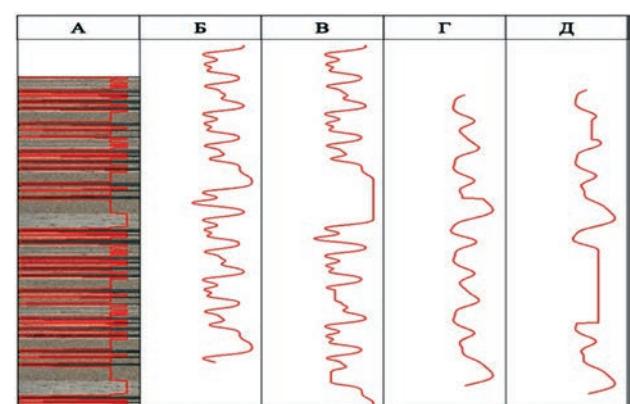
В данной работе предлагается новый подход к решению вышеописанной проблемы, который позволяет в автоматическом режиме выполнить увязку данных ГИС и фотографий полноразмерного керна. Причём разработанная методика применима не только для задач сопоставления по глубине данных ГИС с фотографиями керна в дневном и ультрафиолетовом

свете, но и для увязки с данными компьютерной томографии [10]. Научная новизна нашего подхода заключается в том, что для привязки данных ГИС используется литологическая модель, построенная по фотографиям в автоматическом режиме. Исследуемые кривые отражают реальную структуру разреза и должны быть согласованными с литологической моделью. В настоящей статье продемонстрирована эффективность предлагаемого подхода по результатам обработки синтетических данных ГИС с различными искажениями, имитирующие искажения при записи реальных приборов.

Постановка задачи. Задача привязки каротажной кривой к фотографиям керна заключается в поиске такого положения кривой или отдельных её частей, в котором каротажная кривая верно описывает изменение свойств в заданном интервале. Границы пластов, различимые на фотографиях керна и на каротажной кривой, должны соответствовать друг другу в привязанном состоянии. Для демонстрации работы методики была создана синтетическая скважина, состоящая из 3 литотипов терригенного месторождения: песчаник, уголь и алевролит (рис. 1 А). Помимо этого была составлена высокоразрешенная блоковая кривая плотности (обозначена красным на рис. 1 А), с учётом того, что значение плотности одинаково для определенных литотипов и постоянно в пределах каждого интервала. Синтетическая каротажная кривая плотности была получена сглаживанием высокоразрешенной кривой фильтром Гаусса с базой ~ 80 см (рис. 1 Б, В) и ~ 160 см (рис. 1 Г, Д), имитируя измерение прибором для плотностного каротажа.

Помимо сдвига на постоянное значение (рис. 1 Б) в работе также рассмотрены и другие распространенные случаи встречающихся искажений при записи, в частности затяжки (рис. 1 В, Д). Затяжки (stick-slip) возникают, когда статическая сила, необходимая для начала движения записывающего прибора в скважине, превышает возможности подъемного устройства [11]. Помимо этого, на рис. 1 Г представлена кривая плотности, сдвинутая на постоянную величину с небольшой потерей данных ($\sim 10\%$). Кривая на рис. 1 Д значительно искажена затяжками, причём потери данных составляют $\sim 40\%$.

Рис. 1. Различные случаи искажения каротажной кривой:
А - фотографии керна и высокоразрешенная кривая, Б - сдвиг на постоянную величину, В - кривая с затяжками, Г - кривая с потерянной информацией, Д - кривая с затяжками и потерянной информацией



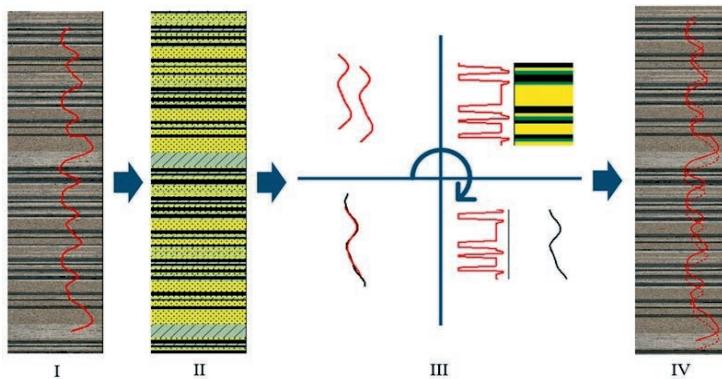


Рис. 2. Общая схема методики автоматической увязки данных ГИС.

Цель настоящей работы – выполнить автоматическую увязку сдвинутой каротажной кривой плотности с фотографиями полноразмерного керна с учётом того, что каротажная кривая может быть искажена.

Общая схема предлагаемой методики автоматической увязки данных ГИС представлена на рис. 2.

На этапе I у нас имеются фотографии керна и данные ГИС, требующий уточнения по глубине. Вначале выполняется автоматическое литотипирование по фотографиям керна, по результатам которого имеем литологическую модель II. На следующем этапе выполняется автоматический процесс увязки предобработанной кривой III, подробно описанный в разделе «Алгоритм увязки данных». В результате выполнения данного алгоритма получаем таблицу сдвигов (shift table), применив которую к исходной кривой (сплошная), получаем уточненную кривую (пунктирная) IV.

Важным шагом увязки фотографий керна и данных ГИС является построение литологической модели по имеющимся фотографиям керна, причём фото могут быть доступны как в дневном, так и в ультрафиолетовом освещении. В литературе представлено несколько подходов для получения литологической модели, в том числе с применением сверточных нейронных сетей [8]. Однако в данной работе используется методика, основанная на анализе текстурных и цветовых кривых-предикторов алгоритмами машинного обучения. Предлагаемая методика подробно описана в работах [5, 6, 15] и обладает большей гибкостью и универсальностью по сравнению с обработкой изображения сверточными сетями. Помимо этого, алгоритмы требуют для обучения гораздо меньше времени, что позволяет оперативно дообучать модели при наличии новых данных. Процесс автоматического литотипирования фотографий керна, представленных на рис. 3 Б, состоит из следующих этапов:

- подготовка фотографий к обработке
- получение текстурных и цветовых кривых-предикторов
- разметка данных для обучения, создание зонации (рис. 3 А)
- обучение предсказывающих моделей (алгоритм случайного леса или полно связной нейронной сети) [2, 14]
- контроль качества обучения (графики loss-функций и важности признаков)
- применение обученных алгоритмов и получение литологической модели (рис. 3 В)

- проверка качества автоматического литотипирования (визуальный осмотр, анализ метрик и матриц ошибок).

Предложенный подход позволяет совместно обрабатывать не только фотографии в дневном и ультрафиолетовом свете, но и данные компьютерной томографии керна, что повышает качество литотипирования. Степень детализации полученной литологической колонки определяется качеством входных данных: разрешением изображений, наличием артефактов, связанных с фотографированием и непосредственным состоянием керна. В случае наличия связанных данных ГИС корректность модели также может быть подтверждена сравнением с объемной минералогической моделью, либо с привлечением информации по соседним скважинам. Ещё одним преимуществом предлагаемого подхода автоматического литотипирования является возможность использовать дополнительную геолого-геофизическую информацию для создания литологической модели: имеющееся литологическое описание керна, выделенные границы между литотипами, кривую профильной проницаемости и т.п.

Алгоритм автоматической увязки. Как было показано выше основной недостаток существующих автоматических методик увязки данных ГИС заключается в применении чисто «численных» подходов: анализ степени схожести кривых, поиск и привязка пиков, методы кросс-корреляции и т.п.



Рис. 3. Литологическая модель, полученная методикой автоматического литотипирования.

При этом такие подходы не позволяют учитывать геологическую информацию (которую содержат каротажные кривые) и сводят задачу к формальной минимизации какой-либо метрики.

Таким образом, появляется риск получения «нефизических» результатов. Нами был разработан алгоритм, который позволяет применять имеющуюся информацию о строении разреза (литологическую колонку с рис. 3 В) на любом этапе увязки. Основу методики составляет алгоритм поэтапных обратных сверток (деконволюций), описанный ниже.

Алгоритм поэтапных обратных сверток. Идея использовать поэтапные деконволюции для обработки кривых ГИС не нова. Например, ещё в 1995 году в работе [17] был предложен метод тонкослоистого анализа под названием Synergetic High Resolution Analysis and Reconstruction for Petrophysics Evaluation (SHARP). Подход позволяет увеличить разрешение стандартных каротажных данных, используя информацию с высокоразрешенных методов каротажа (например, удельное сопротивление). Со временем появлялись различные усовершенствования и модификации данного алгоритма [7, 9], позволяющие автоматизировать и упростить деконволюцию кривых.

Согласно [17] показания прибора $\langle T \rangle$ на конкретной глубине z_i это сложная функция, которая может быть описана в цилиндрических координатах (r, θ, z) :

$$\langle T \rangle = F(r, \theta, z_i, V_1(r, \theta, z) \dots V_j(r, \theta, z), g_1 \dots g_j),$$

где $V_j(r, \theta, z)$ – объём фации j ,

g_j – функция отклика прибора для фации j .

Далее, согласно модальной инверсии [17], сделаем ряд стандартных предположений:

- текущее измерение прибора не зависит от угла наклона θ , радиуса r и объёмов фаций $V_j(r, \theta, z)$, а только от глубины z_i
- текущее измерение прибора представляет собой свёртку с некоторым оператором $g(z)$ – функцией отклика прибора
- известно количество фаций (мод) и границы между ними

Используя определение свертки из функционального анализа в дискретном случае, обозначим показания прибора на конкретной глубине через $\langle S(z_i) \rangle$:

$$\langle S(z_i) \rangle = \sum_{k=0}^i g(z_i - z_k) S(z_k) \quad (1)$$

Где g – известная функция отклика прибора, а S – эффективное измерение прибора при максимальном разрешении (бесконечный пласт, истинное значение для каждой фации). Суммирование в выражении производится по шагам дискретизации k в интервале от 0 до i интересующих глубин. При этом S принимает только дискретные значения, которые мы назовём модами:

$$S \in \{S_1, S_2, \dots, S_N\} \quad (2)$$

В настоящей работе предлагается определять границы пластов и число мод N из полученной литологической модели, т.к. итоговое разрешение такой модели определяется качеством исходных фотографий и может достигать нескольких мм. Зная измеренные значения $\langle T \rangle$, рассчитанные $\langle S \rangle$, функцию отклика $g(z)$, границы пластов и число мод, можно получить S – истинные значения свойств фаций (плотность, пористость, естественная радиоактивность и т.п.).

Введём бинарные базисные функции h_n , которые принимают значение 0 или 1 и обладают свойством ортогональности:

$$h_n(z_i) \in \{0, 1\} \quad \forall z_i, \forall n \in \{1, \dots, N\} \quad (3)$$

$$\sum_i h_n(z_i) h_p(z_i) = 0 \quad (4)$$

$$\forall n, p: n, p \in \{1, \dots, N\} \wedge n \neq p$$

При этом

$$\sum_{n=1}^N h_n(z_i) = 1 \quad \forall z_i \quad (5)$$

Учитывая дискретность значений, выразим $S(z_i)$ через базисные функции

$$S(z_i) = \sum_{n=1}^N h_n(z_i) S_n \quad (6)$$

Где $S(z_i) = S_n$, если и только если $h_n(z_i) = 1$
Уравнение (1) тогда принимает вид

$$\langle S(z_i) \rangle = \sum_{n=1}^N H_n(z_i) S_n \quad (7)$$

Где

$$H_n(z_i) = \sum_{k=0}^i g(z_i - z_k) h_n(z_k) \quad (8)$$

Для заданной слоистости базисные функции постоянны и неизвестные значения S_n ищутся из условия минимизации суммы квадратов разностей измерений $\langle T(z) \rangle$ и рассчитанных каротажных значений $\langle S(z) \rangle$:

$$\min \sum_i [\langle T(z_i) \rangle - \langle S(z_i) \rangle]^2 \rightarrow 0 \quad (9)$$

Введём следующие обозначения

\hat{S} – вектор рассчитанных значений размера ($M \times 1$), M – число точек кривой (шагов дискретизации)

S – вектор значений мод размера ($N \times 1$), N – число мод

H – матрица базисных функций размера ($M \times N$)

T – вектор измеренных значений размера ($M \times 1$)

Тогда

$$\hat{S} = H * S \quad (10)$$

Согласно формуле (10), минимизируем следующий функционал

$$\min \|T - \hat{S}\|^2 = \min \|T - H * S\|^2 \quad (11)$$

Найдём производную по целевой переменной S

$$\frac{\delta(T - H * S)^2}{\delta S} = 0 \quad (12)$$

$$H^T H S - H^T T = 0 \quad (13)$$

Выражаем решение

$$S = (H^T H)^{-1} H^T T \quad (14)$$

Выражения для индексов имеют вид:

$$[H^T H]_{kl} = \sum_i H_k(z_i) H_l(z_i) \quad 1 \leq k \leq N; 1 \leq l \leq N \quad (15)$$

$$[H^T T]_k = \sum_i H_k(z_i) T(z_i) \quad 1 \leq k \leq N \quad (16)$$

Функция отклика g – важное допущение алгоритма поэтапных деконволюций. В целом, это трёхмерная функция, но для первого приближения она была выбрана одномерной. Также для нашего случая не так важна точность деконволюции, т.к. мы лишь ищем оптимальное положение участка кривой. В будущем, можно принять во внимание зависимость от радиуса (для учёта загрязнения околоскважинного пространства фильтратом бурового раствора) и от азимута (для учёта анизотропии). Также в работе было учтено дополнительное предположение, что сверточный оператор g не зависит от амплитуды сигнала. Важным шагом алгоритма поэтапных обратных свёрток является получение информации о количестве фаций и о границах. В данной работе для этих целей используется литологическая модель, полученная методикой автоматического литотипирования. Стандартный же подход к их определению заключается в анализе гистограмм и кросс-плотов данных высокого разрешения (например, данных электрического каротажа).

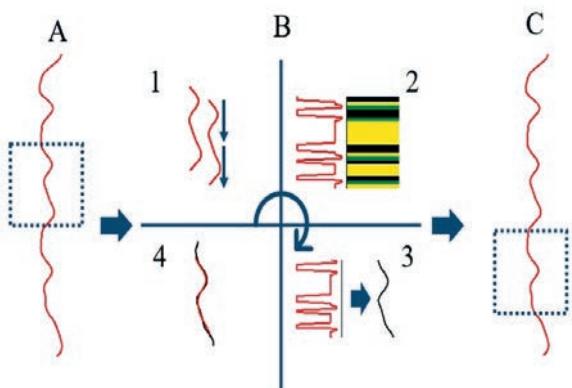


Рис. 4. Схема алгоритма увязки.

Автоматический процесс увязки. В настоящей работе предлагается использовать алгоритм повышения разрешения данных ГИС для поиска оптимального положения привязываемой каротажной кривой. Исходя из предположения о том, что исследуемая кривая до своего сдвига отображала реальные параметры среды, существует оптимальное (исходное) положение, когда она совпадает с рассчитанной кривой $\langle S(z_i) \rangle$ для заданного разреза. Именно определение такого положения и является результатом привязки. Такой подход позволяет учесть особенности геологического строения, т.к. в процессе деконволюции вычисляются реальные величины исследуемых фаций. Автоматических процесс увязки каротажной кривой выполняется по следующему циклическому алгоритму (рис. 4).

С помощью окна фиксированного размера выбирается небольшая часть кривой. Варьируя размер окна, можно менять точность увязки, при этом окно не может быть меньше разрешения прибора (рис. 4 А).

- Сдвигаем выбранный участок кривой на шаг дискретизации (рис. 4 В 1).
- Используя границы пропластков с литологической модели, получаем данные высокого разрешения с помощью применения алгоритма поэтапных обратных свёрток (рис. 4 В 2).

• Из высокоразрешенной кривой с помощью свёртки с функцией отклика прибора получаем восстановленные значения (рис. 4 В 3). По сути, рассчитанная кривая есть результат решения прямой задачи, вычисленный по формуле (8).

- Оцениваем степень схожести исходной (сплошной) и восстановленной (прерывистой) кривой (рис. 4 В 4). Это можно определить не только “визуальным” сравнением, но и количественной мерой контроля совпадения двух кривых. В качестве метрики выбрана NRMSE, рассчитываемая по формуле

$$NRMSE = \frac{\sqrt{\frac{1}{I} \sum_{i=1}^I (\langle T_i \rangle - \langle S_i \rangle)^2}}{\langle T \rangle} \quad (17)$$

Где $\langle T \rangle$ – исходная кривая (сплошная), $\langle S \rangle$ – восстановленные кривые (прерывистая). Стоит отметить, что ввиду наличия некоторой неопределённости в литологической модели и в кривой высокого разрешения (в силу сделанных предположений), восстановленная и исходная кривая могут не совпадать в оптимальном положении. Но при этом в таком положении совпадение будет лучше, чем в любом другом. Этапы 1-4 на рис. 4 В выполняются до тех пор, пока не будет рассчитана и записана метрика для каждого шага дискретизации в пределах интервала увязки. Обычно интервал увязки составляет 2-3 м.

- Сдвигаем окно на шаг (рис. 4 С), равный размеру окна (чтобы избежать наложения кривых друг на друга) и повторяем алгоритм заново.

Процесс выполняется до тех пор, пока не будет обработана вся исходная кривая. По результатам обработки формируется матрица размера $M \times L$, содержащая значения NRMSE, где M – число участков

кривой выбираемых на рис. 4 А, а L – число шагов дискретизации в интервале увязки. Таким образом для каждого участка кривой выбирается оптимальное положение, обеспечивающее минимальное значение метрики.

Полученные результаты. В результате применения настоящего подхода было уточнено положение синтетических данных ГИС, представленных в разделе «Постановка задачи». Результаты показаны на рис. 5.

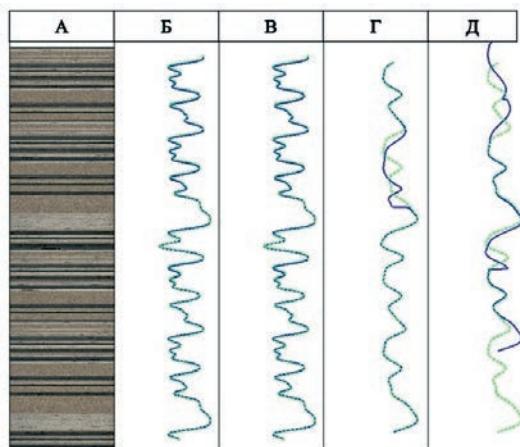


Рис. 5. Результаты обработки синтетического набора данных.

Так как скважина была синтетической, то известны исходные положения каротажных кривых плотности до сдвига. Соответственно, сравнивая уточнённые кривые (сплошные) с истинной (пунктир), можно делать вывод о качестве привязки. Случай Б и В демонстрирует идеальную привязку, кривые полностью совпадают. Для случая Г не получилось привязать ту часть кривой, где данные отсутствовали, причем участки кривой выше и ниже отсутствующего интервала тоже привязались идеально. Случай Д

демонстрирует результат увязки кривой, которая была значительно искажена затяжками. Несмотря на значительные потери данных (~ 40%) алгоритм верно привязал центральную часть кривой, что составляет ~50% от исходной.

Выводы

Применение предложенного подхода позволило впервые решить проблему сопоставления изменения кривых ГИС с глубиной с фотографиями полноразмерного керна в автоматическом режиме. По результатам обработки синтетического набора данных для плотностного каротажа были уточнены глубины сбора данных ГИС с точностью до 10 см (величина шага дискретизации данных). Алгоритм демонстрирует высокое качество увязки для данных, сдвинутых на постоянную величину и искажённых затяжками. В предложенном подходе используется алгоритм автоматической литотипизации, который позволяет получать надёжную литологическую колонку по фотографиям полноразмерного керна и данным компьютерной томографии.

Применение литологической колонки во время увязки позволяет учитывать геологическое строение разреза, что улучшает точность работы алгоритма. Ввиду того, что операции деконволюции выполняются за очень короткое время, предложенный алгоритм можно рассматривать как инструмент для быстрой проверки степени увязки начальных данных, что также расширяет области использования методики. Таким образом, данный подход может быть полезен для улучшения точности геофизических исследований скважин и определения ФЕС тонкослоистых пропластков горных пород в околоскважинном пространстве.

Дата положительной рецензии 04.06.2024

automated rock typing // Computers & Geosciences. 2020. (135). P. 104330.

9. *Bordakov G. A., Kliegl M. V., Goswami J. C. Robust Well Log Sharpening With Unknown Tool Response Function 2015.*

10. *Damaschke M. et al. Unlocking national treasures: The core scanning approach // Geological Society, London, Special Publications. 2023. № 1 (527). P. SP527-2022.*

11. *Gupta S., Chatar C., Celaya J. R. Machine learning lessons learnt in stick-slip prediction OnePetro, 2019.*

12. *Kerzner M. G. A solution to the problem of automatic depth matching SPWLA, 1984.P. SPWLA-1984.*

13. *Koroteev D., Tekic Z. Artificial intelligence in oil and gas upstream: Trends, challenges, and scenarios for the future // Energy and AI. 2021. (3). P. 100041.*

14. *Makienko D., Seleznev I., Safonov I. The effect of the imbalanced training dataset on the quality of classification of lithotypes via whole core photos // Creative Commons License Attribution. 2020. (4).*

15. *Seleznev I. et al. Joint usage of whole core images obtained in different frequency ranges for the tasks of automatic lithotype description and modeling of rocks' petrophysics properties European Association of Geoscientists & Engineers, 2020.P. 1–5.*

16. *Sircar A. et al. Application of machine learning and artificial intelligence in oil and gas industry // Petroleum*

Литература

1. Акиньшин А. В., Кантемиров Ю. Д. Практическое руководство по интерпретации геофизических исследований скважин 2021.
2. Коссоб Г. А., Селезнев И. А. Влияние настраиваемых параметров полносвязной нейронной сети на качество предсказания для задачи классификации литотипов // Проблемы информатики. 2023. № 1 (58). С. 48–59.
3. Кузнецова Г. Методические приемы привязки керна к геофизическим исследованиям // Территория Нефтегаз. 2017. № 1–2. С. 20–26.
4. Петерслье В., Пороскун В., Яценко Г. Методические рекомендации по подсчету геологических запасов нефти и газа объемным методом // Москва-Тверь. 2003.
5. Abashkin V. et al. Digital analysis of the whole core photos European Association of Geoscientists & Engineers, 2020.P. 1–5.
6. Abashkin V. V. et al. Quantitative analysis of whole core photos for continental oilfield of Western Siberia SPE, 2020.P. D043S020R007.
7. Allen D. F., Bordakov G. Method for quantifying resistivity and hydrocarbon saturation in thin bed formations 2009.
8. Baraboshkin E. E. et al. Deep convolutions for in-depth

- Research. 2021. № 4 (6). P. 379–391.
17. Tabanou J. R., Antoine J. Method and apparatus for detecting and quantifying hydrocarbon bearing laminated reservoirs on a workstation 1995.
18. Torres Caceres V. A. et al. Automated well-log depth matching—1d convolutional neural networks vs. classic cross correlation // Petrophysics. 2022. № 01 (63). P. 12–34.
19. Zimmermann T., Liang L., Zeroug S. Machine-learning-based automatic well-log depth matching // Petrophysics. 2018. № 06 (59). P. 863–872.

References

1. Akinshin A. V., Kantemirov Y. D. Prakticheskoe rukovodstvo po interpretacii geofizicheskikh issledovanij skvazhin 2021.
2. Kossov G. A., Seleznev I. A. Vliyanie na straivaemyh parametrov polnosvyaznoj nejronnoj seti na kachestvo predskazaniya dlya zadachi klassifikacii litotipov // Problemy informatiki. 2023. № 1 (58). P. 48–59.
3. Kuznecova G. Metodicheskie priemy privyazki kerna k geofizicheskim issledovaniyam // Territoriya Neftgaz. 2017. V. 1–2. P. 20–26.
4. Petersile V., Poroskun V., Yacenko G. Metodicheskie rekomendacii po podschetu geologicheskikh zapasov nefti i gaza obemnym metodom // 2003.
5. Abashkin V. et al. Digital analysis of the whole core photos European Association of Geoscientists & Engineers, 2020. P. 1–5.
6. Abashkin V. V. et al. Quantitative analysis of whole core photos for continental oilfield of Western Siberia SPE, 2020. P. D043S020R007.
7. Allen D. F., Bordakov G. Method for quantifying resistivity and hydrocarbon saturation in thin bed formations 2009.
8. Baraboshkin E. E. et al. Deep convolutions for in-depth automated rock typing // Computers & Geosciences. 2020. (135). P. 104330.
9. Bordakov G. A., Kliegl M. V., Goswami J. C. Robust Well Log Sharpening With Unknown Tool Response Function 2015.
10. Damaschke M. et al. Unlocking national treasures: The core scanning approach // Geological Society, London, Special Publications. 2023. № 1 (527). P. SP527-2022.
11. Gupta S., Chatar C., Celaya J. R. Machine learning lessons learnt in stick-slip prediction OnePetro, 2019.
12. Kerzner M. G. A solution to the problem of automatic depth matching SPWLA, 1984. P. SPWLA-1984.
13. Koroteev D., Tekic Z. Artificial intelligence in oil and gas upstream: Trends, challenges, and scenarios for the future // Energy and AI. 2021. (3). P. 100041.
14. Makienko D., Seleznev I., Safonov I. The effect of the imbalanced training dataset on the quality of classification of lithotypes via whole core photos // Creative Commons License Attribution. 2020. (4).
15. Seleznev I. et al. Joint usage of whole core images obtained in different frequency ranges for the tasks of automatic lithotype description and modeling of rocks' petrophysics properties European Association of Geoscientists & Engineers, 2020. P. 1–5.
16. Sircar A. et al. Application of machine learning and artificial intelligence in oil and gas industry // Petroleum Research. 2021. № 4 (6). P. 379–391.
17. Tabanou J. R., Antoine J. Method and apparatus for detecting and quantifying hydrocarbon bearing laminated reservoirs on a workstation 1995.
18. Torres Caceres V. A. et al. Automated well-log depth matching—1d convolutional neural networks vs. classic cross correlation // Petrophysics. 2022. № 01 (63). P. 12–34.
19. Zimmermann T., Liang L., Zeroug S. Machine-learning-based automatic well-log depth matching // Petrophysics. 2018. № 06 (59). P. 863–872.

Об авторах:



**АБАШКИН
Владимир Викторович**

окончил МФТИ в 2001 году. Защитил диссертацию, с присвоением ученой степени к.ф.-м.н. в 2010 году. Области научных интересов: взаимодействие ионизирующего излучения и плазмы с твердым телом, механика пористой среды, машинное зрение, цифровой анализ керна.



**КОССОВ
Георгий Андреевич**

аспирант 1 курса Московского Физико-Технического Института. Окончил бакалавриат и магистратуру МФТИ по специальности «Прикладная математика и физика». Область научных интересов включает в себя компьютерное зрение, глубокое обучение, методы оптимизации